

GEO Explorer — 品牌 AI 可见度监测与优化平台

项目介绍文档 v2 | 生成时间: 2026-06-03 | 版本: P2 全完成 + ClaimNature v2

一、项目概述

1.1 GEO Explorer 是什么

GEO Explorer 是一套 **品牌 AI 认知资产管理平台**，系统性地监测、诊断并优化品牌在 AI 平台（DeepSeek、Kimi、豆包等）中的可见度和认知准确度。

它的核心命题是：**当用户向 AI 询问关于你的品牌、行业、产品的问题时，AI 回答正确吗？完整吗？有竞争力吗？**

一句话概括：让你的品牌在 AI 眼中是正确、完整、有竞争力的。

1.2 解决的核心问题

问题	具体表现	GEO Explorer 的应对
品牌"黑盒"	你不知道 AI 怎么说你的品牌——有没有被提及？描述准确吗？	多平台系统性质询，量化 10 个 KPI
AI"幻觉"	AI 编造品牌信息（如总部地点、营收数据），误导消费者决策	4 层幻觉检测 + GT 核验 + 声明性质分类
认知"碎片化"	不同 AI 平台对同一品牌的描述互相矛盾	跨平台一致性监测 + 证据来源追溯
修复"无闭环"	发布纠正内容后不知道 AI 是否已更新认知	历史重归因 + Content Package + 人审反馈闭环
竞争"缺对标"	不知道竞品在 AI 中的表现如何	竞品对比 + 行业 KPI 基准 + 品牌差异化分析

1.3 适用对象

- 品牌方**：市场部/数字营销团队，监测品牌 AI 形象
- 代理机构**：为多个客户提供 GEO 诊断和优化服务（多租户架构）

- **平台运营**：监测 AI 平台的内容质量，识别系统性偏见
- **覆盖行业**：餐饮零售、金融保险、医疗健康、教育培训、SaaS、汽车、文旅等 11 个行业

二、系统架构

2.1 技术栈

层级	技术选型	说明
语言	Python 3.12	全异步 (async/await)，类型标注
Web 框架	FastAPI 0.136	REST API + Jinja2 模板 + HTMX 2.0
ORM + 迁移	SQLAlchemy 2.0 async + Alembic	异步查询，JSONB 支持，29 个迁移
数据库	PostgreSQL 16 (Docker)	主库 5432 + 测试库 5433
任务队列	Celery + Redis 7	异步采集，长任务不阻塞 HTTP
前端	Jinja2 + HTMX + Chart.js 4.4 + Tailwind CDN	42 个模板，真实后端集成
AI 平台	DeepSeek / Kimi / 豆包 / 文心	统一 OpenAI-compatible 适配器
报告输出	Puppeteer + marked + python-docx	三格式：Markdown + Word + PDF
部署	Systemd 守护进程	geo-redis / geo-celery / geo-api

2.2 项目规模


维度	数量
Python 源文件	210+
Jinja2 模板	42
数据库表	81
Alembic 迁移	29
测试用例	613 (0 failures)
GitHub	https://github.com/05ffh/GEO-Explorer


2.3 目录结构

```
explore geo/  
├─ src/  
│   └─ models/           # 81 张数据表的 ORM 模型  
│   └─ adapters/         # AI 平台适配器 (DeepSeek/Kimi/豆包/文心)
```

└─ collector/	# 采集引擎 + GT 自动采集
└─ analyzer/	# 10 KPI 计算 + 幻觉检测 + ClaimNature 分类
└─ actions/	# Action 引擎 + Content Package 生成
└─ api/	# REST API 端点 (20+ endpoint)
└─ services/	# 业务服务 (证据验证/人审反馈/模板校验/样本充分度)
└─ reports/	# 报告生成 + PDF/DOCX 导出
└─ schemas/	# GT v2 字段定义 + 行业配置 + 字段注册表
└─ view_models/	# 前端视图模型
└─ templates/	# 42 个 Jinja2 模板 (含 14 个 partial 组件)
└─ auth/	# JWT 认证 + 双层角色权限
└─ publishing/	# CMS 发布适配器
└─ queue/	# 任务队列监控
└─ benchmark/	# 性能基准测试
└─ seed/	# 种子数据 (行业模板/风险关键词)
└─ infra/	# 基础设施 (缓存/限流/重试)
└─ tests/	# 57 个测试文件, 613 tests
└─ fixtures/claim_taxonomy/	# ClaimNature 中文黄金样本集
└─ regression/	# 回归测试
└─ alembic/	# 29 个数据库迁移
└─ deploy/	# systemd 服务文件
└─ docs/superpowers/	# 设计规范 + 实现计划
└─ reports/	# 品牌诊断报告输出

三、完整业务链路 — GEO 诊断的 7 个环节





环节 1：GT 采集（Ground Truth — 品牌"事实档案"）

目的：建立品牌的可信事实基准，作为后续所有 KPI 计算和幻觉检测的依据。

流程：

- 1. 用户输入品牌名称 → 系统向多个 AI 平台发送预设查询（如"{{品牌}} 总部位于哪里""{{品牌}} 成立于哪一年"）
- 2. 同时通过 DuckDuckGo 搜索补充公开信息
- 3. 字段级证据聚合：每个 GT 字段（如 official_name、founded_year、store_count）独立评分
- 4. 生成 GroundTruthCandidate（候选事实），包含每个字段的值、置信度、证据来源

来源等级体系：

等级	含义	权重	示例
S	官方一手来源	5	品牌官网、年报、官方公告
A	权威第三方来源	4	政府备案、行业监管文件、权威媒体
B	可信媒体/专业机构	3	知名媒体、研究机构报告
C	普通网页/百科/二手	2	Wikipedia、普通资讯站
D	未验证线索	1	论坛、社交媒体、AI 推测

为什么重要：GT 是整个系统的基石。如果 GT 不准确，所有 KPI 计算和幻觉判定都不可信。

环节 2：GT 审核（人工 + 证据双重阻断）

目的：确保 GT 的准确性——AI 采集的结果必须经过人工确认才能用于 KPI 计算。

流程：

1. 审核工作台展示每个 GT 字段的候选值和多条证据来源
2. 人工逐字段审核：接受 / 编辑 / 删除 / 标记不确定
3. 高风险字段（official_name、industry、category 等）强制确认
4. 冲突检测：同一字段不同来源给出不同值 → 标记需人工裁定
5. 审核通过 → Promote 为 active GroundTruthVersion（正式 GT）
6. 旧版本自动标记为 superseded，保留完整历史

v2 增强：

- 字段类型标签（string / list / number / object）
- 单字段内联编辑 UI
- 来源 tier 徽标（S/A/B/C/D）直观展示证据质量

环节 3：品牌 GEO 采集（系统性 AI 质询）

目的：了解 AI 平台在当前状态下如何描述目标品牌。

流程：

1. 使用 **22 个标准查询模板** 覆盖 8 种问题类型：
 - 品牌定义（"{{品牌}} 是什么"）
 - 品牌属性（"{{品牌}} 的核心特点"）
 - 品牌对比（"{{品牌A}} 和 {{品牌B}} 哪个更好"）
 - 品牌信任（"{{品牌}} 靠谱吗"）
 - 品类推荐（"推荐几个咖啡品牌"）
 - 场景方案（"上班困了喝什么咖啡"）
 - 用户推荐（"你推荐星巴克吗"）
 - 通用建议（"如何选择咖啡品牌"）
2. 向 **4 个 AI 平台**（DeepSeek/Kimi/豆包/文心）并发发送查询
3. 采集 AI 的完整回复，记录延迟、引用来源、渲染状态
4. 模板健康前置检查：无效模板 >20% 则阻断采集

模板版本化：模板修改后自动生成新版本，正在进行的采集不受影响，支持历史版本查看和回滚。

环节 4：幻觉检测 + KPI 计算（引擎核心）

目的：量化品牌 AI 认知质量，检测 AI 对品牌的错误表述。

4.1 幻觉检测（4 层架构）

第 1 层 — 声明提取：从 AI 回复中提取品牌相关的事实性声明片段。例如："星巴克总部位于西雅图" → 提取声明 总部=西雅图，匹配 GT 字段 headquarters。

第 2 层 — 声明性质分类（ClaimNature v2）：每条声明标注认知性质：

分类	含义	处理方式
FACT	可验证的客观事实	进入事实准确率校验，与 GT 对比
OPINION	主观评价/判断	不进入事实准确率分母，标注观点倾向
SPECULATION	前瞻性/未证实推测	独立风险评级，不等于幻觉
UNKNOWN	无法判定	进入人审队列

分类器采用加权评分制：强信号 +2 分、弱信号 +1 分、数字/结构模式 +1 分，冲突阈值 1.3x → UNKNOWN。否定窗口检测（信号词前后 5 字符）、n-gram 回退匹配、行业高风险词库（金融/医疗/教育）。

评估指标（100 样本中文黄金集）：准确率 77.0%，UNKNOWN 率 20.0%，推测召回 85.7%，事实精确 86.0%。

第 3 层 — 事实核验（n-gram + LLM-as-Judge）：

- 声明与 GT 进行分词模糊匹配（n-gram overlap）
- 边界案例（相似度 0.05-0.35）由 LLM-as-Judge 二次判定
- Severity 输出：P0（严重错误）、P1（重要偏差）、P2（细微差异）、Info（非错误）
- Verdict 输出：supported / contradicted / unsupported / not_checkable / ambiguous 等 9 种判定

第 4 层 — 多证据 GT 交叉验证（P2-2）：

- 同一字段的多条 GT 证据加权共识（S=5/A=4/B=3/C=2/D=1 + 官方来源 × 1.2）
- 冲突分级：none / weak / moderate / strong / critical
- 证据冲突不等于 AI 幻觉——来源间争议单独标注，不计入幻觉计数
- 证据强度：strong / moderate / weak / disputed / insufficient_evidence

4.2 10 个核心 KPI

KPI	中文名	计算逻辑
SOV	声量份额	品牌在 AI 回复中被提及的频率 / 总查询数
First Recommendation Rate	首次推荐率	非品牌场景问题中首个被推荐的比率
Accuracy	事实准确率	AI 品牌声明与 GT 一致的比例（仅 FACTS 进入分母）
Completeness	信息完备性	GT 关键字段在 AI 回复中的覆盖率
Citation Rate	来源引用率	AI 回复中引用官方来源的比率
Scenario Recall	场景联想率	非品牌场景词下品牌被提及的比例
Semantic Stability	语义锚点稳定度	不同平台对品牌核心描述的相似度
Differentiation	差异化程度	品牌独特卖点在 AI 表述中的出现率
Cross-Platform Consistency	跨平台一致性	品牌关键声明的跨平台稳定性
Recommendation Quality	推荐理由质量	AI 推荐理由的实质性和准确度

每个 KPI 包含：数值、样本量（denominator）、置信度、按平台/问题类型的分维数据。

环节 5：Action Themes + Content Package（从诊断到修复）

目的：诊断发现问题后，自动生成修复方案。

5.1 Action Theme 聚合

- 将幻觉结果按字段维度聚合为 Action Theme（如 official_name / industry / category）
- 每个 Theme 包含：影响的 AI 声明列表、GT 正确值、建议纠正内容
- P0/P1/P2 优先级分级，生成状态机看板（pending → in_progress → completed → verified）

5.2 Content Package 生成

- 基于 Action Themes 按内容主题聚类
- LLM（DeepSeek）生成完整可发布内容：
 - 品牌介绍（结构化事实描述）
 - FAQ（常见问题 + 基于 GT 的标准答案）
 - 场景推荐（品牌适用场景）
 - 竞品对比（与竞品的主要差异）
- 每个 Package 包含：风险分级、事实检查标注、发布检查清单、Schema.org JSON-LD

环节 6：报告交付

三格式输出（缺一不可）：

格式	用途	工具
.md	技术审阅、版本控制	marked
.docx	企业汇报、协作编辑	python-docx
.pdf	正式交付、演示分发	Puppeteer + marked

报告内容：诊断摘要 + 10 KPI 仪表板 + 幻觉详情（P0/P1/P2 分级）+ 声明性质分布 + 证据强度分析 + 行业高风险检查 + Action Theme 清单 + 优化建议 + Go/No-Go 发布判定。


报告质量闸门：

- 8 个硬阻断条件（如模板健康度 <60%、核心 KPI 分母为 0）
- 声明性质阻断：推测占比 >50% / UNKNOWN 占比过高
- 证据强度阻断：关键字段 A/S 级来源冲突 / 弱证据占比 >60%
- 4 个软警告（如可选模板跳过、单平台覆盖率 <50%）

环节 7：人审闭环 + 持续优化

目的：分类器不可能一次完美，必须接入人工审核形成持续改进飞轮。

审核流：



3 类反馈动作：

1. **GT 修正：**人工判 contradicted 且有修正值 → 生成 GTUpdateCandidate → GT reviewer 二次审核（不自动修改 GT）
2. **模板优化：**同一 pattern 反复出现 → 标记模板需调整
3. **检测器校准：**误报/漏报模式 → 导出校准样本供分类器改进

审计追溯： HallucinationReviewLog 为 append-only 不可变审计日志，记录每次审核的完整 before/after snapshot (verdict / severity / claim_nature / evidence_strength)。

四、辅助模块

4.1 模板审核工作台 (P2-3)

- 状态机: draft → in_review → active / changes_requested → archived
- 变量/类型/行业/KPI 全校验 (TemplateValidationService)
- 渲染预览 (示例值替换, 发布前必须通过校验)
- 版本历史 + 回滚 + 克隆
- KPI 矩阵: 8 种 question_type × 5 KPI 的 recommended / allowed / blocked

4.2 行业差异化配置 (P1-9)

每个行业独立配置：

- KPI 权重 (金融行业 accuracy 权重更高, SaaS 行业 scenario_recall 权重更高)
- 幻觉阈值 (金融/医疗行业 stricter)
- 声明性质阈值 (UNKNOWN 上限、推测阻断阈值)
- 受监管行业模式 (max_unknown_ratio=0.10 vs 默认 0.20)
- 行业高风险词库 (金融：保本/刚兑/无风险；医疗：治愈/根治/无副作用；教育：保过/包就业)

4.3 历史重归因 (P1-8)

- 检测器升级后，对历史数据重新运行检测
- original vs corrected 双视图，不覆盖原始结果
- 重归因批次状态: draft → in_progress → completed / cancelled
- dry_run 模式：完整计算但不写入业务结果

4.4 前端操作台 (完整后端集成)

页面	功能
品牌总览 Dashboard	10 KPI + GT 统计 + 采集状态
GT 审核	字段审核 + 证据展示 + 内联编辑 + Promote
AI 证据	声明核验链 + 证据强度 + 来源追溯 + 冲突展示

页面	功能
幻觉风险	幻觉结果列表 + 审核队列 + 人审工作台
Action 工作台	Kanban 5 列看板 + ActionPlan 表格 + 状态流转
趋势归因	Chart.js 双面板 + HTMX 范围切换 + 事件时间线
Content 管理	内容包列表 + 状态分布 + 风险徽标 + 发布操作
模板管理	模板列表 + 编辑器 + 校验报告 + 版本历史
报告下载	历史报告列表 + 三格式下载
队列监控	Celery 任务状态
组织设置	多租户管理

五、系统的价值

5.1 对品牌的直接价值

1. **消除 AI 黑盒**：首次让你看到 AI 如何描述你的品牌，量化了原本不可见的"认知资产"
2. **发现并修复幻觉**：AI 编造的品牌信息可能影响消费者决策——GEO Explorer 让你在客户看到之前先发现并修复
3. **竞品对标**：知道竞品在 AI 中的表现，发现差异化机会
4. **持续监测**：不是一次性诊断，而是持续监测 + 闭环优化

5.2 技术架构价值

1. **GT 三层模型**：Candidate → Review → Version，AI 采集结果不直接用于 KPI 计算，必须人工确认
 2. **OPINION ≠ 幻觉，SPECULATION ≠ 幻觉**：不会因为 AI 说"星巴克最好喝"就标记为事实错误——声明性质分类是这个判断的基础
 3. **证据冲突 ≠ AI 幻觉**：GT 来源间争议单独标注，不混淆"来源不确定"和"AI 说错"
 4. **声明级 traceability**：每条 AI 声明可以追溯到 GT 来源、证据等级、审核历史
 5. **异步任务架构**：品牌采集（88 次 AI 调用）和 GT 采集（30+ 次 AI 调用）异步执行，API 立即返回
- 202

5.3 工程方法价值

1. **Define → Plan → Build → Verify → Review → Ship**：6 阶段工程师模式，不跳步

- 2. Spec → 桌面审阅 → 补齐清单 → Build → 有效性验证：需求对齐机制，避免方向性返工
- 3. 613 tests, 0 failures：核心逻辑由测试护卫，重构有底气
- 4. 完整踩坑记录 + Retrospective：知识沉淀，跨会话可复用

六、当前局限与不足之处

6.1 数据采集层

问题	影响	优先级
Wenxin API Key 过期	4 个 AI 平台中仅 3 个可用（DeepSeek/Kimi/豆包），文心 0/23 全失败	☒ 高
Doubao/Kimi 限流严重	采集成功率低（Doubao 3/23, Kimi 5/23），需间隔 >30min	☒ 高
GT 来源以 C 级为主	证据强度普遍 weak，依赖 AI 采集和搜索结果，缺少 S/A/B 级官方来源	☒ 高
DeepSeek 是唯一稳定平台	22/23 成功率，但单平台依赖有风险	☒ 中

6.2 检测与分类

问题	影响	优先级
OPINION recall 偏低 (43.5%)	部分观点声明因信号词不匹配被归为 UNKNOWN	☒ 中
UNKNOWN precision 偏低 (30%)	14 个 fp—— 部分事实/观点被误归为 UNKNOWN	☒ 中
英文分类未独立评估	当前验证集仅中文，英文分类精度未知	☒ 低

6.3 部署与运维

问题	影响
无 Docker Compose 一键部署	当前需手动配置 PostgreSQL Docker + Redis systemd + Celery + API 四个服务
无 CI/CD	没有自动化测试流水线，依赖手动 pytest
无监控告警	API/采集异常无自动通知

6.4 业务覆盖

问题	影响
尚未覆盖 Google AI Overview / SGE	搜索引擎 AI 摘要（如 Google SGE）是重要的 GEO 场景但尚未接入
尚未接入社交媒体 AI	小红书/抖音的 AI 搜索和推荐场景未覆盖
Content Package 仅 DeepSeek 生成	Kimi/Doubao 因 failover 设计不参与内容生成（与采集的多平台并发不同）

七、如何运行

7.1 环境要求

- Python 3.12 + .venv
- PostgreSQL 16（Docker 容器 exploregeo-db-1，端口 5432）
- Redis 7（systemd 服务 geo-redis，端口 6379）
- Node.js 22（PDF 生成用 Puppeteer）

7.2 启动

```
# 启动数据库和 Redis
docker start exploregeo-db-1 exploregeo-test_db-1
sudo systemctl start geo-redis geo-celery geo-api
```

```
# 访问
open http://localhost:8000/login
# 一键登录: test@geo.com / test123
```

7.3 运行诊断

```
# 创建品牌
curl -X POST http://localhost:8000/api/brands \
  -H "Authorization: Bearer <token>" \
  -d '{"name": "你的品牌", "industry": "餐饮"}'

# 触发 GT 自动采集（异步）
curl -X POST http://localhost:8000/api/brands/{brand_id}/gt-collect
```

```
# 等待完成后，审核 GT → Promote

# 触发 GEO 诊断采集（异步）
curl -X POST http://localhost:8000/api/brands/{brand_id}/collections

# 查看 Dashboard → 审核幻觉 → 生成报告
```

八、文件索引

文件/目录	说明
src/analyzer/claim_taxonomy.py	ClaimNature v2 分类器（评分+否定窗口+n-gram+行业词库）
src/analyzer/hallucination.py	4 层幻觉检测 + ClaimNature 集成
src/analyzer/quality.py	报告质量闸门（8 hard blocks + 4 soft warnings）
src/analyzer/pipeline.py	分析管线（KPI→幻觉→Action→Content→报告）
src/collector/engine.py	品牌采集引擎（异步+限流+重试）
src/services/evidence_cross_validator.py	多证据 GT 交叉验证
src/services/review_feedback_service.py	人审反馈闭环
src/services/template_validation_service.py	模板校验
src/api/ground_truth.py	GT 审核 + Promote + 单字段编辑 API
src/api/hallucinations.py	幻觉结果 + 审核队列 API (13 endpoints)
src/api/templates.py	模板 CRUD + 校验 + 预览 API (11 endpoints)

文件/目录	说明
src/reports/delivery.py	统一报告交付（三格式）
src/templates/gt_review/index.html	GT 审核工作台 v2
src/templates/hallucinations/index.html	幻觉审核工作台
tests/fixtures/claim_taxonomy/zh_claim_nature_golden.jsonl	100 样本中文黄金集
tests/test_claim_taxonomy_eval.py	ClaimNature 评估脚本 (per-class metrics)

GEO Explorer v2 | 2026-06-03 | 210+ 源文件 | 42 模板 | 81 数据表 | 29 迁移 | 613 tests (0 failures)